

Raport - Metody Systemowe i Decyzyjne grupa 2

Wojciech Majchrowski¹[0009-0005-4030-6084], Alicja Wieczorek²[orcidAli], and
Jakub Karolewski³[orcidKuby]

Faculty of Information and Communication Technology,
Wroclaw University of Science and Technology, 50-372 Wrocław, Poland
wojciech.piotr.majchrowski@gmail.com, ala.wieczorek.0805@gmail.com,
karolewski.jakub@gmail.com

Introduction

Współczesny paradygmat oceny jakości, stabilności oraz długoterminowego potencjału przedsiębiorstw przeszedł na przestrzeni ostatniej dekady drastyczną transformację. Historycznie, wycena korporacji opierała się niemal wyłącznie na tradycyjnych metodach budżetowania kapitałowego oraz twardych wskaźnikach finansowych, takich jak Wartość Zaktualizowana Netto (NPV), marża zysku, czy Wewnętrzna Stopa Zwrotu (IRR).¹ Zmiany klimatyczne, rosnąca presja regulacyjna oraz transformacja oczekiwań interesariuszy wymusiły jednak ewolucję w stronę modeli uwzględniających czynniki środowiskowe, społeczne i ładu korporacyjnego (ESG). Integracja tych zróżnicowanych domen danych stwarza bezprecedensowe wyzwania analityczne. Dane ESG są często obciążone subiektywizmem, wysokim stopniem niepewności, brakiem rynkowej standaryzacji oraz skomplikowaną strukturą nieliniowych powiązań z wynikami finansowymi.⁴ Zjawiska te sprawiają, że tradycyjne, binarne lub ściśle liniowe modele oceny stają się niewystarczające, prowadząc do zniekształceń w wycenie ryzyka inwestycyjnego i utrudniając obiektywne kategoryzowanie przedsiębiorstw.

W odpowiedzi na te fundamentalne trudności badawcze, zastosowanie logiki rozmytej (ang. fuzzy logic) wyłania się jako wysoce adekwatna, zaawansowana metodologia, która pozwala na modelowanie niepewności i płynnych przejść między stanami. W przeciwieństwie do logiki klasycznej, gdzie firma może być sklasyfikowana wyłącznie jako "zrównoważona" lub "niezrównoważona", logika rozmyta operuje na stopniach przynależności, idealnie odzwierciedlając złożoność świata rzeczywistego. Poniższy raport stanowi wyczerpującą, przekrojową analizę zaawansowanego rurociągu badawczego, który integruje reguły eksperckie w ramach hierarchicznego systemu rozmytego (HFS) z algorytmiczną, statystyczną selekcją cech za pomocą Analizy Głównych Składowych (PCA). Eksperyment ten, operujący na rozbudowanym zbiorze danych łączącym metryki finansowe i fizyczne wskaźniki ESG, stanowi istotny krok w kierunku zautomatyzowania i obiektywizacji oceny korporacyjnej.

Related Works

Przegląd dotychczasowej literatury i projektów badawczych z pogranicza analizy finansowej oraz ESG ukazuje dwa dominujące, lecz rzadko integrowane nurty metodologiczne: podejście oparte na algorytmach uczenia maszynowego typu *black-box* oraz systemy decyzyjne wykorzystujące logikę rozmytą.

0.1 Machine Learning and Statistical Approaches in ESG

Pierwszy nurt opiera się na zastosowaniu klasycznych metod statystycznych oraz uczenia maszynowego do poszukiwania zależności między wskaźnikami ESG a wydajnością finansową. Chaouech (2025) w swoich badaniach wykorzystał szerokie spektrum algorytmów regresyjnych i zespołowych (w tym Random Forest, XGBoost oraz LightGBM) do przewidywania wyników ESG na podstawie danych finansowych i środowiskowych [2]. Podobne eksperymenty można zaobserwować w otwartych repozytoriach analitycznych na platformie Kaggle. Autorzy tacy jak Payasli [7], Kifayatullah [4] oraz Amri [1] przeprowadzili wielowymiarową analizę zbioru *ESG and Financial Performance Dataset*, wykorzystując zaawansowane modele gradientowe (XGBoost, LightGBM) oraz metody statystyczne do ekstrakcji wiedzy z danych. Mimo wysokiej skuteczności predykcyjnej, algorytmy te posiadają istotną wadę: działają jak "czarne skrzynki" (ang. *black-box models*), co znacznie utrudnia interpretację logiki biznesowej stojącej za konkretną wyceną firmy. Co więcej, statystyczna redukcja wymiarowości (np. za pomocą Analizy Głównych Składowych - PCA) często prowadzi do utraty semantycznego znaczenia cech wejściowych, zacierając granicę między oceną finansową a etyczną (ESG).

0.2 Fuzzy Logic in Financial Decision-Making and ESG

W odpowiedzi na problemy z interpretowalnością uczenia maszynowego oraz niepewnością danych ESG, drugi nurt badawczy wykorzystuje teorię zbiorów rozmytych. Kompleksowy przegląd zastosowań logiki rozmytej w decyzjach inwestycyjnych ESG zaprezentowali Lochab i Batra (2025), wykazując, że techniki te doskonale radzą sobie z subiektywnością i niejednoznacznością inherentną dla wskaźników niefinansowych [6]. Konkretnym przykładem implementacji tego paradygmatu jest praca Ragazou i in. (2025), w której zastosowano rozmyty model hybrydowy (AHP-MARCOS) do oceny transformacji cyfrowej i ekologicznej zasobów ludzkich w erze ESG [8]. Modele te udowadniają, że wiedza ekspercka może zostać skutecznie zakodowana w postaci reguł lingwistycznych, zachowując wysoką transparentność (ang. *explainability*).

0.3 Hierarchical Architectures in Complex Environments

W przypadku wielowymiarowych analiz, w których liczba reguł rozmytych rośnie wykładniczo, konieczne staje się stosowanie systemów hierarchicznych (ang. *Hierarchical Fuzzy Systems* - HFS). W obszarze monitorowania ryzyka finansowego

wykazali to Krimpas i in. (2026), opracowując hierarchiczne rozmyte mapy kognitywne (FCM) służące do agregacji koncepcji finansowych i przewidywania upadłości przedsiębiorstw [5]. Zastosowanie hierarchii pozwala na podział złożonego problemu decyzyjnego na mniejsze, w pełni niezależne bazy reguł (np. oddzielna ewaluacja stabilności ESG i oddzielna wycena wskaźników wzrostu), co zapobiega zjawisku tzw. "przekleństwa wymiarowości" (ang. *curse of dimensionality*).

Biorąc pod uwagę powyższy przegląd, istnieje widoczna luka badawcza w zakresie bezpośredniego, empirycznego porównania wiedzy eksperckiej zamodelowanej poprzez Hierarchiczny System Rozmyty (HFS) z wiedzą wyekstrahowaną algorytmicznie poprzez analizę statystyczną (PCA). Niniejsza praca ma na celu wypełnienie tej luki poprzez symulację rynkową zestawiającą wyniki optymalizacji portfelowej osiągnięte przez oba te podejścia.

1 Methodology

1.1 Description of Pipeline

Zaprojektowany potok przetwarzania (ang. *data pipeline*) realizuje wieloetapową transformację wielowymiarowych danych panelowych w jednoznaczne oceny rankingowe (ang. *Target Scores*). Celem architektury jest umożliwienie bezpośredniego porównania skuteczności heurystycznego, wielopoziomowego wnioskowania rozmytego z czysto algorytmiczną redukcją przestrzeni cech. Całość procesu badawczego ustrukturyzowano w kilka komplementarnych faz.

Agregacja ekonometryczna i inżynieria cech. Pierwotny zbiór danych zawiera informacje o charakterze szeregów czasowych z lat 2020–2023 dla sześciu podstawowych atrybutów przedsiębiorstw: przychodów (*Revenue*), marży zysku (*ProfitMargin*), kapitalizacji rynkowej (*MarketCap*), stopy wzrostu (*GrowthRate*), ogólnego wskaźnika ESG (*ESG_Overall*) oraz zysku netto (*NetIncome*). W celu kompresji wymiaru czasowego i ekstrakcji długoterminowych trendów, w module `utils.py` zaimplementowano cztery metryki statystyczne dla każdej zmiennej pierwotnej:

- *Średnia ważona krocząca (WMA)*: Przypisująca wyższe wagi latom najnowszym, co pozwala uchwycić aktualną dynamikę spółki.
- *Odchylenie standardowe (std)*: Określające absolutną zmienność parametru w badanym okresie.
- *Współczynnik zmienności (cv)*: Definiowany jako stosunek odchylenia standardowego do średniej, umożliwiający bezwymiarowe porównanie ryzyka między podmiotami o różnej skali działalności.
- *Regresja liniowa (Slope)*: Współczynnik kierunkowy prostej trendu, reprezentujący globalny wektor wzrostu lub regresu danej cechy.

Po dokonaniu agregacji dane poddano czyszczeniu (usunięcie wartości nieskończonych i imputacja braków danych wartościami neutralnymi) oraz standaryzacji Z-score, sprowadzając je do porównywalnych przedziałów rynkowych. Przed przystąpieniem do modelowania, rozkłady statystyczne cech oraz wpływ wartości odstających zweryfikowano eksperymentalnie w notebooku `data_distribution.ipynb`.

Konstrukcja Eksperckich Podsystemów Rozmytych. Na bazie wyekstrahowanych metryk zbudowano dwa niezależne systemy wnioskowania rozmytego typu Mamdaniego, reprezentujące odmienne paradygmaty analityczne:

- **Podsystem A (Zrównoważony rozwój i stabilność):** Zaimplementowany w pliku `fuzzy_rules_27.ipynb`, koncentruje się na synergii między efektywnością finansową a profilowaniem ryzyka ESG. Wykorzystuje trzy wejściowe zmienne rozmyte: rentowność inwestycji (*Earnings Yield*), wzrost skorygowany o ryzyko (*Risk-Adjusted Growth*) oraz wskaźnik stabilności raportowania niefinansowego (*ESG_Signal-to-Noise*). Baza wiedzy składa się z 27 reguł eksperckich promujących spółki stabilne ekologicznie i fundamentalnie.
- **Podsystem B (Agresywny wzrost finansowy):** Opisany w skrypcie `new_fuzzy_rules_wojtek.ipynb`, świadomie pomija aspekty etyczne (ESG) w celu wyeliminowania korelacji między podsystemami i skupia się wyłącznie na dynamice kapitałowej. Jako zmienne wejściowe przyjmuje: relację zysku do wzrostu (*Earnings-to-Growth*), wycenę sprzedaży (*PriceToSales*) oraz historyczną stabilność marży (*ProfitMargin_WMA*). System ten operuje na trapezoidalnych funkcjach przynależności podzielonych na 3 lingwistyczne stopnie intensywności (*low, medium, high*).

Integracja Hierarchiczna (HFS). Wyniki ewaluacji (*Target Score A* oraz *Target Score B*), stanowiące wyjściowe ostre wartości z deofuzyfikacji podsystemów, zostały potraktowane jako zmienne wejściowe (tzw. *antecedents*) dla nadrzędnego systemu rozmytego wyższego rzędu (Meta-FIS). Proces integracji oraz ostatecznej syntezy wskaźnika atrakcyjności inwestycyjnej realizowany jest w komponencie `Hierarchical_Fuzzy_Systems.ipynb`.

Algorytmiczna Redukcja Wymiarowości (Ścieżka PCA). Równolegle do eksperckiej dekompozycji problemu, cały ustandaryzowany zbiór danych poddano matematycznej Analizie Głównych Składowych w module `pca.ipynb`. Kryterium odcięcia ustawiono na zachowanie 75%–80% skumulowanej wariancji. Poprzez analizę wektorów własnych (ładunków składowych) zidentyfikowano trzy cechy o najwyższej globalnej zmienności informacyjnej: zmienność przychodów (*Revenue_cv*), zysk netto (*NetIncome*) oraz stabilność ESG (*ESG_Signal-to-Noise*). Cechy te posłużyły do zasilenia alternatywnego, jedopoziomowego systemu rozmytego opartego na PCA, opisanego w noteboku `PCA_based_rules.ipynb`.

Backtesting i Ewaluacja Portfelowa. W końcowej fazie potoku oba podejścia (HFS oraz PCA-based FIS) zostają poddane walidacji rynkowej w symulowanym środowisku inwestycyjnym na rok 2025 za pomocą skryptu `sim.py`. Algorytm dokonuje alokacji kapitału początkowego (100 000 PLN) w portfele o różnym stopniu koncentracji (top 3, top 10 oraz top 30 najwyżej ocenionych spółek). Końcowa stopa zwrotu z obu strategii jest bezpośrednio porównywana z benchmarkiem szerokiego rynku, co pozwala na empiryczną ocenę przewagi hierarchii rozmytej nad czystą statystyką wielowymiarową.

1.2 Dataset

W badaniu wykorzystano zbiór danych *ESG and Financial Performance Dataset*, stanowiący ustrukturyzowany zestaw danych panelowych (ang. *panel data*) dla 1000 globalnych przedsiębiorstw, rejestrowanych w ujęciu rocznym w latach 2020–2023. Choć pierwotny zbiór zawiera szereg metryk kategoriowych i identyfikacyjnych — takich jak unikalny identyfikator podmiotu (`CompanyID`), nazwa firmy (`CompanyName`), sektor przemysłu (`Industry`) oraz region geograficzny (`Region`) — projektowany system wnioskowania rozmytego oraz algorytmy redukcji wymiarowości opierają się ściśle na wektorze pięciu kluczowych zmiennych ciągłych (ilościowych):

$$X = \{\text{Revenue}, \text{ProfitMargin}, \text{MarketCap}, \text{GrowthRate}, \text{ESG_Overall}\} \quad (1)$$

Przed przystąpieniem do inżynierii cech, w środowisku `data_distribution.ipynb` przeprowadzono głęboką eksplorację statystyczną rozkładów pierwotnych. Wykorzystując estymator gęstości jądrowej (ang. *Kernel Density Estimation* — KDE) oraz analizę miar tendencji centralnej (średnia arytmetyczna μ oraz mediana Me), zidentyfikowano kluczowe właściwości strukturalne generowanego syntetycznie zbioru:

Przychody (Revenue) i Kapitalizacja (MarketCap): Wskaźniki skali działalności przedsiębiorstw charakteryzują się specyficznym uwarunkowaniem rozkładu empirycznego. Wizualizacja gęstości za pomocą histogramów ujawnia relacje między średnią a medianą. W przypadku wystąpienia asymetrii prawostronnej ($\mu > Me$), rynkowi liderzy o skrajnie wysokich przychodach i wycenie generują tzw. długi ogon rozkładu. Taka charakterystyka asymetryczna implikuje, że klasyczne liniowe metody skalowania mogłyby zostać zniekształcone przez pojedyncze obserwacje odstające, co uzasadnia późniejsze zastosowanie zaawansowanych technik odpornej standaryzacji w module `utils.py`.

Marża zysku (ProfitMargin) i Stopa wzrostu (GrowthRate): Parametry opisujące dynamikę i efektywność operacyjną wykazują rozkłady zbliżone do symetrycznych (unimodalnych), gdzie wartości średniej arytmetycznej i mediany niemal całkowicie się pokrywają ($\mu \approx Me$). Świadczy to o stabilnym, zrównoważonym rozproszeniu cech wokół średniej rynkowej, bez dominacji ekstremalnych anomalii. Funkcje przynależności systemów rozmytych dla tych zmiennych mogą dzięki temu operować na jednorodnych, regularnych przedziałach lingwistycznych.

Ogólny wskaźnik ESG (ESG_Overall): Metryka reprezentująca syntetyczną ocenę standardów niefinansowych wykazuje rozkład o wysokiej regularności. Analiza statystyczna potwierdza, że rozkład ten równomiernie pokrywa przestrzeń stanów, a zbieżność średniej i mediany pozwala na precyzyjne wyznaczenie punktów podziału (ang. *breakpoints*) dla trapezoidalnych i trójkątnych funkcji przynależności na poziomach niskim, średnim oraz wysokim.

Pozostałe atrybuty kategoriowe (`Industry`, `Region`) zostały świadomie wykluczone z bezpośredniego modelowania matematycznego. Decyzja ta podyktowana

była koniecznością zapewnienia uniwersalności systemów rozmytych oraz uniknięcia sztucznego zwiększania wymiarowości bazy reguł, co w kontekście systemów hierarchicznych (HFS) i liniowych (PCA) pozwoliło na zachowanie pełnej przejrzystości i porównywalności obu podejść.

Wizualną syntezę opisanych właściwości statystycznych analizowanych zmiennych przedstawiono na wykresie zbiorczym (Fig. 1).




Fig. 1: Rozkłady empiryczne pięciu bazowych zmiennych ilościowych w pierwotnym zbiorze danych wraz z naniesionymi miarami tendencji centralnej.

Graficzna analiza histogramów oraz nałożonych estymatorów gęstości jądrowej (KDE) jednoznacznie potwierdza wcześniejsze wnioski dotyczące geometrii przestrzeni danych. Dla cech *Revenue* oraz *MarketCap* widoczne jest silne skupienie obserwacji w lewej części przedziału i długi prawostronny ogon asymetrii, na co wskazuje również wyraźne przesunięcie zielonej linii średniej w prawo względem czerwonej linii mediany. W opozycji do nich, cechy *ProfitMargin*, *GrowthRate* oraz *ESG_Overall* wykazują niemal idealną zbieżność obu linii ($Me \approx \mu$) wewnątrz symetrycznych, dzwonowatych rozkładów unimodalnych. Stanowi to ostateczne, empiryczne uzasadnienie dla konieczności wdrożenia zróżnicowanych strategii modelowania baz reguł rozmytych i specyficznego definiowania granic przedziałów dla poszczególnych zmiennych lingwistycznych.

1.3 Przetwarzanie wstępne i ekstrakcja cech

Surowe dane panelowe, charakteryzujące się wielowymiarowością czasową (lata 2016-2025), wymagały zastosowania zaawansowanych technik agregacji oraz inżynierii cech, aby mogły posłużyć jako stabilne wejście do systemów logiki rozmytej. Proces ten podzielono na trzy główne etapy: kompresję wymiaru czasowego, syntezę metryk inwestycyjnych oraz standaryzację przestrzeni cech.

Agregacja ekonometryczna. W pierwszej kolejności oryginalne wskaźniki poddano kompresji czasowej w celu redukcji szumu i uchwycenia długoterminowych

trendów przedsiębiorstwa. Dla każdej z bazowych zmiennych wyznaczono wektor czterech statystyk opisowych:

1. **Średnia ważona krocząca (WMA):** Przypisuje najwyższe wagi najnowszym obserwacjom, co pozwala na precyzyjniejsze odzwierciedlenie aktualnej kondycji spółki. Wyraża się wzorem:

$$WMA = \frac{\sum_{i=1}^n w_i \cdot x_i}{\sum_{i=1}^n w_i} \quad (2)$$

gdzie x_i to wartość cechy w i -tym roku, a $w_i = i$ stanowi liniowo rosnącą wagę chronologiczną.

2. **Odchylenie standardowe (σ):** Klasyczna miara zmienności i rozproszenia wyników w analizowanym okresie.
3. **Współczynnik zmienności (CV):** Stosunek odchylenia standardowego do średniej arytmetycznej (w implementacji zastąpionej przez WMA), pozwalający na bezwymiarowe porównanie ryzyka dla firm o różnej skali operacyjnej:

$$CV = \frac{\sigma}{WMA} \quad (3)$$

4. **Współczynnik kierunkowy (Slope):** Parametr a z równania regresji liniowej ($y = ax + b$), modelujący dynamikę oraz kierunek historycznego trendu.

Synteza Metryk Inwestycyjnych. Wykorzystując zagregowane statystyki, skonstruowano wysoce wyspecjalizowane wskaźniki analityczne, które znacznie lepiej odzwierciedlają fundamentalną wartość spółki niż proste zmienne księgowe:

- **NetIncome (Szacowany Zysk Netto):** Przychód określa jedynie wolumen przepływów pieniężnych, dlatego realny sukces operacyjny firmy wyliczono jako: $NetIncome = Revenue_{WMA} \times \left(\frac{ProfitMargin_{WMA}}{100} \right)$.
- **EarningsYield (Rentowność Zysków):** Odwrotność klasycznego wskaźnika ceny do zysku (P/E), wyliczana jako $\frac{NetIncome}{MarketCap_{WMA}}$. Wartości ujemne naturalnie penalizują spółki generujące straty.
- **Risk-AdjustedGrowth (Wzrost Skorygowany o Ryzyko):** Zdefiniowany jako stosunek $\frac{GrowthRate_{WMA}}{GrowthRate_{std}}$, co promuje organizacje o stabilnym, wysoce przewidywalnym rozwoju.
- **ESG_Signal-to-Noise:** Miara przeciwdziałająca zjawisku *greenwashingu*, obliczana poprzez $\frac{ESG_Overall_{slope}}{ESG_Overall_{cv}}$. Premiuje spółki, w których poprawa standardów zrównoważonego rozwoju jest silna i pozbawiona nagłych wahań.
- **PriceToSales (P/S) oraz Earnings-to-Growth (Zmodyfikowany PEG Ratio):** Złożone metryki oceniające relację wyceny giełdowej do wzrostu, w których niższe wartości implikują wyższą atrakcyjność inwestycyjną.

Eliminacja defektów algorytmicznych (Problem Podwójnego Minusa). Istotnym wyzwaniem analitycznym w metrykach ilorazowych jest obsługa firm w głębokiej zapaści fundamentalnej. W przypadku wskaźnika *Earnings-to-Growth* (będącego relacją wyceny P/E do wzrostu skorygowanego o ryzyko), jeśli spółka generuje stratę ($NetIncome < 0$) oraz jej wzrost jest ujemny ($Risk-AdjustedGrowth < 0$), arytmetyczne dzielenie dwóch wartości ujemnych zwraca fałszywie dodatni, niski wynik. W rezultacie system rozmyty zinterpretowałby upadające, deficytowe przedsiębiorstwo jako doskonałą okazję inwestycyjną. Aby zapobiec tej tzw. "pułapce podwójnego minusa", wdrożono bezwarunkową karę algorytmiczną – spółkom niespełniającym podstawowych kryteriów zyskowności sztucznie przypisuje się maksymalną (najgorszą) wartość kary na poziomie 95. percentyla rozkładu tej cechy.

Czyszczenie danych i standaryzacja (Z-score). W ostatniej fazie przetwarzania, po wyeliminowaniu błędów typu dzielenia przez zero (`inf`) oraz imputacji braków `NaN`, całą przestrzeń wejściową poddano odpornej standaryzacji statystycznej. Transformacja ta sprowadza zróżnicowane jednostkowo metryki (np. wartości zysku w dolarach i wartości ESG w punktach) do ujednoliconego zakresu wariancji z wartością oczekiwaną równą 0 i odchyleniem standardowym równym 1. Zastosowano klasyczny wzór:

$$Z = \frac{x - \mu}{\sigma} \quad (4)$$

gdzie x to oryginalna wartość metryki, μ to średnia rynkowa dla danej kolumny, a σ to jej odchylenie standardowe. Dzięki takiemu zabiegowi, parametry wejściowe systemów logiki rozmytej oraz sieci PCA mogły bezpośrednio interpretować pozycję danej spółki względem globalnego tła rynkowego.

W celu zweryfikowania geometrii nowo powstałej przestrzeni cech oraz przygotowania środowiska pod definicję zbiorów rozmytych, wygenerowano rozkłady empiryczne dla sześciu wyliczonych metryk inwestycyjnych (Fig. 2).




Fig. 2: Rozkłady empiryczne docelowych metryk inwestycyjnych w uciętym przedziale ufności (między 5. a 95. percentylem). Na wykresach naniesiono pionowe linie oznaczające położenie mediany oraz średniej arytmetycznej dla zredukowanego zbioru.

Ze względu na zastosowanie bezwarunkowych kar algorytmicznych (sztuczne przypisywanie ekstremalnie wysokich wartości dla spółek deficytowych w metryce *Earnings-to-Growth*) oraz naturalne rynkowe wartości skrajne (np. spółki o mikroskopijnej kapitalizacji zaburzające wskaźniki ilorazowe), pełne rozkłady cech byłyby wizualnie i statystycznie nieczytelne. Z tego powodu na wykresach zastosowano filtrację rynkowego szumu, prezentując wyłącznie rdzeń danych – obserwacje znajdujące się pomiędzy 5. a 95. percentylem rozkładu.

Taki zabieg analityczny (zbliżony do statystycznej winsoryzacji) ujawnił rzeczywisty kształt gęstości prawdopodobieństwa dla wskaźników takich jak *NetIncome*, *EarningsYield*, *Risk-AdjustedGrowth*, *ESG_Signal-to-Noise*, *PriceToSales* oraz *Earnings-to-Growth*. Zbadanie rozstawienia średniej i mediany w tak oczyszczonym oknie pomiarowym miało krytyczne znaczenie dla kolejnej fazy projektu. Pozwoliło to mianowicie na wysoce obiektywne, oparte na gęstości danych wyznaczenie punktów przegięcia (ang. *breakpoints*) dla trójkątnych i trapezoidalnych funkcji przynależności w eksperckich systemach rozmytych, eliminując w ten sposób problem subiektywnego doboru parametrów przez analityka.

1.4 Fuzzy Rules

W ramach eksperymentu opracowano i zestawiono ze sobą dwie odmienne architektury systemów wnioskowania rozmytego (typu Mamdaniego): bazującą na wiedzy eksperckiej architekturę hierarchiczną (HFS) oraz system sterowany danymi na bazie Analizy Głównych Składowych (PCA-based FIS). Oba rozwiązania korzystają ze znormalizowanych, trójstopniowych funkcji przynależności, rozdzielających przestrzeń wejściową na zbiory lingwistyczne: *low*, *medium* oraz *high*.

Ekspercki Hierarchiczny System Rozmyty (HFS). Model ten opiera się na głębokiej integracji dwóch niezależnych podsystemów rozmytych. Ich struktura została zaprojektowana w sposób ściśle ortogonalny – wyselekcjonowane metryki są wzajemnie rozłączne informacyjnie. Aby uniknąć redundancji i współliniowości (np. podwójnego karania lub nagradzania spółki za dwa różne wskaźniki wykorzystujące w mianowniku zmienną *Revenue*), upewniono się, że żaden atrybut bazowy nie powtarza się w logice reguł pomiędzy podsystemami. Prowadzi to do maksymalizacji ekstrakcji wiedzy z dostępnej przestrzeni cech:

- **Podsystem I:** Agreguje informacje z zakresu stabilności zrównoważonego rozwoju oraz bezpiecznej rentowności. Jako zmienne wejściowe wykorzystuje: *EarningsYield*, *Risk-AdjustedGrowth* oraz *ESG_Signal-to-Noise*.
- **Podsystem II:** Skupia się na agresywnej dynamice rynkowej i wycenie spółki przez mnożniki. Jako zmienne wejściowe wykorzystuje: *PriceToSales*, *Earnings-to-Growth* oraz *ProfitMargin_WMA*.

Ostre wartości wyjściowe z obu procesów deofuzyfikacji (tzw. *Target Scores*) są następnie przekazywane jako sygnały wejściowe do nadrzędnego systemu rozmytego (Meta-FIS). W meta-bazie reguł oba te podsystemy są traktowane jako obiektywnie równoważne (posiadają identyczną wagę decyzyjną), a ich agregacja generuje ostateczną ocenę inwestycyjną (*Final Score*) dla badanej spółki.

System oparty na Analizie Głównych Składowych (PCA-based FIS). Drugie podejście całkowicie eliminuje arbitralność ludzkiego eksperta, powierzając dobór metryk algorytmowi uczenia nienadzorowanego. Architektura tego systemu została podyktowana wynikami dwuetapowej selekcji cech (ang. *Feature Importance*) za pomocą algorytmu PCA:

1. **Faza redukcji wewnątrzgrupowej:** W pierwszej kolejności algorytm przeanalizował zróżnicowanie statystyczne wewnątrz pierwotnych atrybutów, pozostawiając z każdego z nich tylko jedną, najbardziej nośną informacyjnie cechę z grupy (odrzucając m.in. redundantne miary zmienności czy szumu). Wytypowano w ten sposób pięć atrybutów: *Revenue_cv*, *ESG_Overall_WMA*, *MarketCap_WMA*, *GrowthRate_WMA* oraz *ProfitMargin_std*.
2. **Faza selekcji globalnej:** Otrzymane pięć cech zostało złączonych w jedną macierz z zaawansowanymi metrykami wyliczanymi przez autorów (m.in. *PriceToSales*, *NetIncome*, *EarningsYield*, *Earnings-to-Growth*, *ESG_Signal-to-Noise*) i ponownie poddane dekompozycji wariancji.

Ostateczna iteracja PCA zidentyfikowała trzy składowe o najwyższym wektorze istotności względem wariancji całego zbioru: współczynnik zmienności przychodów *Revenue_cv* (istotność na poziomie 0.252051), zysk netto *NetIncome* (0.237808) oraz *ESG_Signal-to-Noise* (0.237409). Na bazie tych zaledwie trzech zmiennych wejściowych skonstruowano alternatywny system rozmyty. Wykorzystanie identycznej struktury lingwistycznej (zbiory *low*, *medium*, *high*) oraz mechaniki ewaluacji pozwoliło na sprawiedliwe zestawienie obu filozofii (selekcja ludzka vs ekstrakcja statystyczna) w docelowej symulacji portfelowej.


2 Results summary

Celem przeprowadzonej symulacji było przetestowanie i porównanie dwóch odmiennych systemów selekcji spółek giełdowych: modelu opartego na fuzji systemów rozmytych (HFS) oraz modelu opartego na algorytmie redukcji wymiarowości (PCA). Aby zapewnić rzetelność wyników, wszystkie algorytmy były trenowane wyłącznie na historycznych danych z wyznaczonego okresu, a ich skuteczność (stopa zwrotu z wygenerowanych portfeli) była weryfikowana na danych z kolejnego, nieznanego wcześniej modelom roku. Weryfikacja obu modeli została oparta na dwóch zróżnicowanych podejściach symulacyjnych, co pozwoliło zbadać ich wrażliwość na głębokość danych historycznych oraz zmienne warunki rynkowe.


Podstawowa część symulacji została przeprowadzona z wykorzystaniem metody 3-letnich okien przesuwnych. Algorytmy analizowały dane finansowe z trzech kolejnych lat (np. 2016–2018), na podstawie których generowały rekomendacje dla portfeli inwestycyjnych. Następnie symulowano zachowanie tych portfeli w kolejnym roku obrotowym (2019). W kolejnym kroku całe okno analityczne przesuwano o jeden rok do przodu (analiza: 2017–2019, symulacja: 2020), powtarzając proces aż do roku 2025.

Poniższe zestawienie prezentuje graficzne wyniki stóp zwrotu (w ujęciu rocznym) dla portfeli o różnym stopniu koncentracji kapitału (TOP 3, TOP 10, TOP 30) w kolejnych iteracjach symulacyjnych.


ANALIZA: 2016–2018 | SYMULACJA: 2019





ANALIZA: 2017–2019 | SYMULACJA: 2020




ANALIZA: 2018–2020 | SYMULACJA: 2021




ANALIZA: 2019–2021 | SYMULACJA: 2022**ANALIZA: 2020–2022 | SYMULACJA: 2023**


ANALIZA: 2021–2023 | SYMULACJA: 2024



ANALIZA: 2022–2024 | SYMULACJA: 2025



W celu skontrastowania wyników z krótkich okien, przeprowadzono dodatkową, poszerzoną symulację dla roku 2025. W tym podejściu oba modele otrzymały dostęp do pełnego, 9-letniego horyzontu danych historycznych (2016–2024), na podstawie których miały podjąć decyzje inwestycyjne na rok 2025.

ANALIZA: 2016–2024 | SYMULACJA: 2025

Porównanie rezultatów inwestycyjnych uzyskanych w badanym horyzoncie czasowym odsłania fundamentalne różnice w zachowaniu i logice selekcji spółek przez oba testowane podejścia algorytmiczne.

W większości testowanych okresów, przy zastosowaniu krótkich horyzontów analitycznych, HFS zaprezentował wyraźną dominację nad podejściem statystycznym PCA. Model HFS opiera się na bazie wiedzy eksperckiej i regułach logiki rozmytej. Dzięki temu nie wymaga on wieloletniej historii rynkowej, aby trafnie zidentyfikować fundamentalnie zdrowe spółki. System ten wykazał się bardzo wysoką precyzją selekcji (co potwierdza wyższa stopa zwrotu w portfelach skoncentrowanych TOP 3 niż w szerokich TOP 30) oraz wyjątkową zdolnością do wyłapywania rynkowych anomalii i gwałtownych odbić pokryzysowych.

Z kolei algorytm PCA na krótkich próbach badawczych osiągał wyniki wysoce niesatysfakcjonujące. Przy małej liczbie obserwacji historycznych model ten ma tendencję do kompresowania i analizowania szumu informacyjnego oraz losowych wahań rynkowych, zamiast realnych, stabilnych zależności. Ponadto liniowy charakter PCA sprawia, że potrafi on pominąć kluczowe, nieliniowe wartości progowe wskaźników finansowych, które system HFS bez problemu wychwytuje.

Sytuacja uległa jednak diametralnej zmianie po wydłużeniu horyzontu uczącego. W tym scenariuszu model PCA zdołał przełamać dotychczasowy trend i wyprzedzić system HFS w portfelach o najwyższej koncentracji (TOP 3 i TOP 10). Wynika to bezpośrednio z faktu, że zasilenie algorytmu statystycznego dużym zbiorem danych pozwoliło mu na prawidłowe odseparowanie szumu od dominujących, długoterminowych składowych głównych wariacji (globalnych trendów makroekonomicznych). Mając do dyspozycji głęboki szereg czasowy, PCA zidentyfikowało wektory silnego, strukturalnego wzrostu rynku, przewyższając w tym momencie sztywne reguły wbudowane w system ekspercki.

Conclusions and Future Work

Przeprowadzone badania i symulacje inwestycyjne jednoznacznie wskazują, że w obliczu ograniczonej dostępności danych historycznych (krótkie okna czasowe), podejście decyzyjne oparte na wiedzy eksperckiej (Hierarchical Fuzzy System) wykazuje znaczącą przewagę nad metodami czysto statystycznymi (PCA).

Zasadniczą przyczyną tej dysproporcji jest odmienna filozofia selekcji cech. Algorytm Analizy Głównych Składowych (PCA) matematycznie maksymalizuje wariancję – wybiera te kolumny, które najsilniej różnicują zbiór danych pod kątem rozproszenia. Nie oznacza to jednak, że wytypowane w ten sposób atrybuty niosą za sobą fundamentalną, rynkową wartość inwestycyjną. System HFS, oparty na arbitralnym doborze metryk przez analityków, potrafił zidentyfikować wysoce nieliniowe, przyczynowo-skutkowe zależności (takie jak relacja ceny do zysków czy stabilność polityki ekologicznej), które algorytm statystyczny potraktował jako mniej istotne dla globalnej wariancji. Z tego względu ludzka, ekspercka interpretacja wskaźników finansowych i ESG okazała się znacznie bardziej adekwatna do realiów giełdowych.

Należy jednak mocno podkreślić, że wydajność modelu PCA jest wprost proporcjonalna do rozmiaru próby badawczej. Jak wykazała symulacja na wydłużonym horyzoncie, dostarczenie algorytmowi większej liczby lat historycznych pozwala na skuteczne "uśrednienie" wyników i bezbłędne odfiltrowanie krótkoterminowego szumu rynkowego. Płyne z tego wniosek, że w warunkach wielkich zbiorów danych (ang. *Big Data*) statystyczne typowanie parametrów zaczyna ujawniać swój potencjał, z czasem skutecznie modelując długoterminowe cykle koniunkturalne.

Interpretując uzyskane stopy zwrotu, nie można pominąć wpływu globalnych trendów makroekonomicznych zaszytych w badanym zbiorze danych. Cały analizowany rynek znajdował się w fazie silnej, wieloletniej tendencji wzrostowej (tzw. hossy). Zjawisko to nie dotyczyło wyłącznie wskaźników finansowych, ale również standardów niefinansowych – jak wykazano w szczegółowej analizie eksploracyjnej tego zbioru [3], średnia rynkowa wartość syntetycznego wskaźnika *ESG_Overall* systematycznie i liniowo rosła z poziomu 52% w roku 2015 do ponad 57% w roku 2025. Taka ogólnorynkowa poprawa fundamentów w naturalny sposób ułatwiała generowanie dodatnich stóp zwrotu w długim terminie, podnosząc punkt odniesienia (benchmark) dla obu badanych algorytmów.

W ramach przyszłych prac badawczych (*Future Work*) planowane jest rozszerzenie zaprojektowanego rurociągu analitycznego o implementację nowoczesnych modeli uczenia maszynowego (ang. *Machine Learning*), takich jak Random Forest czy XGBoost. Głównym celem będzie wytrenowanie algorytmów predykcyjnych do autonomicznego typowania najbardziej obiecujących spółek i bezpośrednie porównanie wygenerowanych przez nie "portfeli" z portfelami stworzonymi przez nasze systemy logiki rozmytej. Tego rodzaju zestawienie pozwoli na ostateczne rozstrzygnięcie, czy wielowymiarowe modele typu *black-box* są w stanie wygenerować lepszy profil zysku do ryzyka niż wysoce interpretowalne, wielokryterialne systemy eksperckie HFS.

References

1. Amri: Esg and financial performance. <https://www.kaggle.com/code/amri11/esg-and-financial-performance/notebook> (2024), dostę: 2026
2. Chaouech, O.: Predicting corporate esg scores from financial performance and environmental indicators: A machine learning framework. MPRA Paper (2025)
3. Jagtap, S.: Company esg & financial analysis notebook. <https://www.kaggle.com/code/shriyashjagtap/company-esg-financial-analysis-notebook> (2024), dostę: 2026
4. Kifayatullah, E.: Esg financial performance ml 91. <https://www.kaggle.com/code/kifayatullahe/esg-financial-performance-ml-91> (2024), dostę: 2026
5. Krimpas, G.A., Thanasas, G., Krimpas, N.A., Rigou, M., Lampropoulou, K.: Hierarchical fuzzy cognitive maps for financial risk monitoring using aggregated financial concepts. *Journal of Risk and Financial Management* **19**(1), 37 (2026)
6. Lochab, R., Batra, L.: A comprehensive review of fuzzy logic applications in esg investment decision-making with a novel hybrid model application. *Journal of Industrial and Management Optimization* (2025)
7. Payasli, A.: Comparison xgboost & lightgbm (esg and financial). <https://www.kaggle.com/code/alicanpayasli/comparasion-xgboost-lightgbm-esg-and-financial> (2024), dostę: 2026
8. Ragazou, K., Zournatzidou, G., Sklavos, G., Staikouras, C., Sariannidis, N.: Future-proofing the workforce: A fuzzy ahp-marcos model for evaluating green and digital reskilling in the esg era. *Journal of Environmental Management* **396**, 128146 (2025)